



Rayleigh inequality and Schreier matrix and LDL^T decomposition -- how they are composed to generate sum-... ▾

這是一個結合了組合群論、矩陣分析與數值優化（SOS）的高階課題。要將這三者串聯起來生成 A_4 （即對稱群 S_5 ）的平方和（**Sum-of-Squares, SOS**）表示，其核心邏輯是透過對稱群的群代數（Group Algebra）來證明正定性。

以下是這三個組件如何協作的簡要流程：

1. Schreier 矩陣：構建基礎矩陣

在 S_5 的背景，我們研究的是群代數 $\mathbb{R}[S_5]$ 中的拉普拉斯算子（Laplacian）或特定的組合元。

- **作用：** Schreier 矩陣（或 Schreier 圖的鄰接矩陣）描述了群元素在相鄰對換（Adjacent Transpositions $s_i = (i, i + 1)$ ）作用下的轉移關係。
- **構造：** 對於 A_4 型 Coxeter 群（即 S_5 ），生成元集為 $\{s_1, s_2, s_3, s_4\}$ 。Schreier 矩陣 M 記錄了群作用的結構，它是構建「矩陣形式 SOS」的原始材料。

2. LDL^T 分解：實現平方和的代數轉換

SOS 的核心是將一個多項式或群代數元素 P 寫成 $\sum f_i^2$ 。

- **作用：** 當我們把問題轉化為矩陣 Q （通常是基於 Schreier 矩陣構造的半正定矩陣）時，**LDL^T 分解** 提供了一種構造性的方法。
- **過程：** 如果 $Q = LDL^T$ ，其中 D 是對角矩陣且元素非負，那麼：

$$v^T Q v = v^T L D L^T v = \sum d_{ii} (L^T v)_i^2$$

- 這直接將矩陣的正定性證明轉換為一組平方項的加權和。

提出任何問題



AI 模式 全部 圖片 影片 新聞 更多 ▾



... 其 SOS 的聯繫。在證明 S_5 的某個元素（如下節所討論）是正定的時，我們需要證明它大於某個常數。Rayleigh 不等式確保了在進行 LDL^T 分解時，對角線元素 D 的數值穩定性與正定邊界，從而保證 SOS 分解在數值上是可行的。

總結流程

1. **定義**：在 S_5 中以相鄰對換為生成元，構建群代數中的元素（例如： $\Delta = \sum(1 - s_i)$ ）。
2. **矩陣化**：利用 **Schreier 矩陣** 表示該元素在群表示空間中的作用。
3. **分解**：對該矩陣執行 **LDL^T 分解**，將其拆解為基底函數的平方和。
4. **驗證**：利用 **Rayleigh 不等式** 確保特徵值性質，支撐 SOS 證明的收斂性與邊界。 

這套方法常用於證明群論中的性質（如 Kazhdan's property (T)）或尋找群代數的特定下界。

請問您是想針對特定的 **代數元 (Algebraic Element)** 進行數值計算，還是需要更深入了解 S_5 的具體矩陣表示 構造？



 1 個網站



A modification of the Rayleigh test for vector data

It (Rayleigh test) is sensitive to nonrandom concentration or scatter of vector angles, and can be used also to test certain gro...

 Oxford Academic



I need example of the actual Schreier matrix from an actual S5.

AI 模式 全部 圖片 影片 新聞 更多 ▾



$$M_{10 \times 10} = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

對應的排列索引（部分）

- **Index 0:** (1, 2, 3, 4, 5) — 單位元 e
- **Index 1:** (1, 2, 3, 5, 4) — $e \cdot s_4$
- **Index 2:** (1, 2, 4, 3, 5) — $e \cdot s_3$
- **Index 6:** (1, 3, 2, 4, 5) — $e \cdot s_2$

矩陣特性與 SOS 之關聯

1. **稀疏性：**由於 S_5 只有 4 個生成元，每一列（及每一行）精確地只有 4 個非零元素（1）。
2. **Rayleigh 不等式之應用：**在平方和（SOS）分解中，我們會考慮拉普拉斯矩陣 $L = 4I - M$ 。Rayleigh 商可用於估計 L 的最小非零特徵值，這決定了 S_5 群代數中特定正定元（Positive elements）的數值穩定邊界。
3. **LDL^T 分解：**在實際的 SOS 程式碼（如 [SumOfSquares.jl](#) 或 [SCS](#)）中，系統會對該區塊對稱矩陣進行變換（利用群表示論簡化為更小的塊矩陣），然後執行 **LDL^T 分解** 來提取組成平方和的基底多項式（或群元素）。

您是否需要針對特定排列（例如 **Longest element** w_0 ）的轉換路徑進行矩陣分析？

AI 模式 全部 圖片 影片 新聞 更多 ▾



☞ Schreier 矩陣範例（部分區塊）

So for example, row 1, col 1 is 0; row 1, col 2 is 1; what do they mean for group?

這是一個非常具體的結構問題。在 S_5 的 Schreier 矩陣（或 Cayley 圖鄰接矩陣）中，矩陣的列與行代表群中的元素，而數值則代表生成元（Generator）的變換關係。

以下是具體的定義：

矩陣元素的含義

- 列（Row i ）：代表群中的一個排列 σ_i 。
- 行（Column j ）：代表群中的另一個排列 σ_j 。
- 數值 M_{ij} ：
 - 如果 $M_{ij} = 1$ ：表示存在一個生成元 $s \in \{s_1, s_2, s_3, s_4\}$ ，使得 $\sigma_i \cdot s = \sigma_j$ 。也就是說，這兩個排列之間僅差一個「相鄰對換」。
 - 如果 $M_{ij} = 0$ ：表示這兩個排列無法透過「單一個」相鄰對換直接轉換。

以您的例子來說：

假設我們將 S_5 的元素按字典序排列：

1. $\sigma_1 = (1, 2, 3, 4, 5)$ —— 單位元 e
2. $\sigma_2 = (1, 2, 3, 5, 4)$ —— 交換最後兩位的排列
3. $\sigma_3 = (1, 2, 4, 3, 5)$

AI 模式 全部 圖片 影片 新聞 更多 ▾



- $\sigma_1 = (1, 2, 3, 4, 5)$
- $\sigma_2 = (1, 2, 3, 5, 4)$
- 我們發現，只要套用生成元 $s_4 = (4, 5)$ ，即 $\sigma_1 \cdot (4, 5) = \sigma_2$ 。
- 因為兩者之間存在「一步之遙」的關係，所以矩陣對應位置填入 **1**。

這對 SOS（平方和）有什麼用？

在 SOS 分解中，我們要證明一個算子是正定的。這個矩陣告訴我們群元素之間如何「交織」在一起。**LDL^T 分解** 會處理這些「1」，將它們轉化為平方項之間的交叉項（Cross terms），最終讓我們看到整個群結構是如何被拆解成一組平方和的。

您想看看如何對這個 120×120 的大矩陣進行 **塊對角化（Block Diagonalization）** 以簡化計算嗎？



Show me LDL^T decomposition with a small example

為了讓你直觀理解 **LDL^T 分解** 如何在 S_n （如 S_2 或 S_3 ）的背景下生成 **平方和（SOS）**，我們選取一個極簡的例子：對稱群 S_2 的拉普拉斯算子。

1. 設定背景

在 S_2 中，只有兩個元素：

(1, 2) 和單位元

AI 模式 全部 圖片 影片 新聞 更多 ▾



2. 進行 LDL^T 分解

LDL^T 分解的目標是將 A 分解為：

- L (下三角矩陣，對角線為 1)
- D (對角矩陣)

步驟 A：求 L 的第一行與 D_{11}

第一列直接對應： $D_{11} = A_{11} = 2$ 。

$L_{21} = A_{21}/D_{11} = -1/2 = -0.5$ 。

步驟 B：求 D_{22}

$D_{22} = A_{22} - L_{21}^2 \cdot D_{11} = 2 - (-0.5)^2 \cdot 2 = 2 - 0.5 = 1.5$ 。

結果：

$$A = \underbrace{\begin{pmatrix} 1 & 0 \\ -0.5 & 1 \end{pmatrix}}_L \underbrace{\begin{pmatrix} 2 & 0 \\ 0 & 1.5 \end{pmatrix}}_D \underbrace{\begin{pmatrix} 1 & -0.5 \\ 0 & 1 \end{pmatrix}}_{L^T}$$

3. 如何變成「平方和 (SOS)」？

給定一個向量 $v = \begin{pmatrix} x \\ y \end{pmatrix}$ (代表群代數中的係數)，其二次型 $v^T A v$ 表示為：

$$v^T A v = v^T (L D L^T) v = (L^T v)^T D (L^T v)$$

計算 $L^T v$ 。

AI 模式 全部 圖片 影片 新聞 更多 ▾



4. 與 Rayleigh 不等式的聯繫

- **Rayleigh 不等式**：告訴我們這個矩陣的最小特徵值 $\lambda_{\min}$ 。在本例中，特徵值為 1 和 3。
- **意義**：因為 $\lambda_{\min} = 1 > 0$ ，所以 LDL^T 分解中的 D 矩陣元素必定全部為正。這保證了我們可以將其寫成正係數的 **平方和**，從而證明該群運算在 S_2 上是正定的。

在 S_5 的 120×120 矩陣中，原理完全相同，只是 L 會記錄極其複雜的相鄰對換組合關係。

您是否希望我進一步解釋如何利用 **群表示論 (Representation Theory)** 將 S_5 的大矩陣拆解成許多像這樣的小矩陣？



“ 拉普拉斯算子」形式

So it is different from Schreier matrix?

是的，它們有直接的轉化關係，但意義不同。

簡單來說：**Schreier 矩陣**是「地圖」，而拉普拉斯矩陣（Laplacian）是「算子」。

1. Schreier 矩陣 (M)

- **本質**：它是鄰接矩陣 (Adjacency Matrix)。

內容：只記錄「連結」。如果排列 A 透過一個生成元能變成排列 B ，那位置 A 和 B

AI 模式 全部 圖片 影片 新聞 更多 ▾



因為每個元素都有 4 個生成元，所以 $D = 4I$ （對角線全是 4 的矩陣）。

$$L = 4I - M$$

- **外觀：**對角線全是 4，原本 Schreier 矩陣中是 1 的地方變成 -1 。

為什麼 SOS 分解要用「拉普拉斯形式」而不是原來的 Schreier 矩陣？

1. 半正定性 (PSD)：

Schreier 矩陣 M 通常有正有負的特徵值。但拉普拉斯矩陣 L 是半正定的（所有特徵值 ≥ 0 ）。只有半正定的矩陣才能進行 **LDL^T 分解** 並寫成平方和 (SOS)。

2. Rayleigh 不等式的對象：

我們通常用 Rayleigh 不等式來研究 L 的最小非零特徵值（即 **Spectral Gap**）。這代表了群的「擴散速度」或「連通強度」。在 SOS 證明中，這個數值告訴我們這個群表示距離「非正定」還有多大的餘裕。

3. 物理直覺：

- M 告訴你：你可以去哪裡？
- L 告訴你：維持在原地與跳到鄰居之間的「差異」是多少？（這正是 $(x - y)^2$ 這種平方項的來源）。

總結：

當你看到 $2(x - 0.5y)^2 + 1.5y^2$ 這種 SOS 形式時，它背後運算的對象一定是拉普拉斯形式的矩陣，因為只有它能保證分解出來的係數（ D 的元素）是非負的。

您想知道如何從 S_5 的 **Coxeter 關係式**（如 $s_i^2 = 1, (s_i s_{i+1})^3 = 1$ ）直接推導出拉普拉斯矩陣的性質嗎？



AI 模式 全部 圖片 影片 新聞 更多 ▾



and their results?



這是一個非常關鍵的對接問題。要理解矩陣元素如何對應回群運算，我們需要將矩陣看作是**群代數（Group Algebra）**在向量空間上的作用。

以下是映射關係的拆解：

1. 向量空間與基底的映射

在 S_2 的例子中，矩陣的維度是 2×2 ，這對應於 S_2 的兩個群元素。我們定義基底向量為：

- $v_1 = |e\rangle$ （單位元 $(1, 2)$ ）
- $v_2 = |s_1\rangle$ （對換 $(2, 1)$ ）

任何一個群代數元素 $a = c_1 e + c_2 s_1$ 都可以寫成向量 $\begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$ 。

2. 矩陣元素如何對應群運算？

矩陣 A 的每一個位置 A_{ij} 實際上代表了群元素之間的相互作用係數。

對於你提到的矩陣 $A = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$ ：

- 對角線元素 $A_{ii} = 2$ ：
 - 這對應於算子中的 $2e$ 。
 - 意義：當群元素作用在自己身上時（保持原位）的權重。在拉普拉斯算子中，這通常代表「生成元的數量」。
- 非對角線元素 $A_{ij} = -1$ ：
 - 這對應於算子中的 $-s_1$ 。
 - 映射邏輯：因為 Row 1 是 e ，Col 2 是 s_1 ，而群運算告訴我們 $e \cdot s_1 = s_1$ 。

AI 模式 全部 圖片 影片 新聞 更多 ▾



將矩陣乘法展開：

$$(x, y) \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 2x^2 - 2xy + 2y^2$$

這個結果在群論上的物理意義是：

- $2x^2 + 2y^2$ ：是每個元素與生俱來的「能量」（來自 $2e$ ）。
- $-2xy$ ：是元素 e 與 s_1 之間的「相干性」或「交換代價」（來自 $-s_1$ ）。

4. 關鍵：為什麼 LDL^T 分解能「找回」群結構？

當我們把它寫成 SOS 形式 $2(x - 0.5y)^2 + 1.5y^2$ ：

- 括號內的 $(x - 0.5y)$ 反映了群元素之間的相對關係。
- 在 S_5 的 A_4 展示中，這些項會變成形如 $(x_\sigma - x_{\sigma \cdot s_i})^2$ 的項。
- 這證明了：如果兩個排列在 Schreier 圖上是鄰居，它們的係數差異就會被平方項鎖定，從而保證整個群系統的能量（特徵值）永遠大於零。

總結來說：

矩陣的索引（Index）映射到排列（Permutations），矩陣的數值（Values）映射到生成元（Generators）的係數。

你想看看在 S_5 中，一個具體的相鄰對換（例如 s_2 ）如何在 120×120 矩陣的特定位置產生 -1 嗎？



So free group (Tg2) has no commutativity, then what is the

AI 模式 全部 圖片 影片 新聞 更多 ▾



1. 局部 Schreier 矩陣 (M)

在自由群中，沒有任何關係式（除了 $aa^{-1} = 1$ 這種平凡關係）。假設我們觀察單位元 e 及其一階鄰居 $\{a, a^{-1}, b, b^{-1}\}$ ：

若將基底排序為： e, a, a^{-1}, b, b^{-1} ，其局部的鄰接關係（Schreier 矩陣的片段）如下：

$$M_{local} = \begin{pmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \end{pmatrix}$$

- **解釋：**第一列代表 e ，它與其四個生成元鄰居相連。由於沒有迴圈（no commutativity, no relations），除了連回 e 之外，鄰居之間互不相連。

2. 局部拉普拉斯矩陣 (L)

對於 F_2 ，每個頂點的度數（Degree）固定為 $k = 4$ （因為生成元及其逆元共有 4 個）。拉普拉斯矩陣定義為 $L = 4I - M$ ：

$$L_{local} = \begin{pmatrix} 4 & -1 & -1 & -1 & -1 \\ -1 & 4 & 0 & 0 & 0 \\ -1 & 0 & 4 & 0 & 0 \\ -1 & 0 & 0 & 4 & 0 \\ -1 & 0 & 0 & 0 & 4 \end{pmatrix}$$

3. 無交換性（No Commutativity）對矩陣的影響

在 S_5 或其他有限群中，因為有交換律（如 $s_1 s_3 = s_3 s_1$ ），矩陣中會出現閉合路徑。例如，從 e 出發，經過 s_1 再經過 s_3 ，會和經過 s_3 再經過 s_1 到達同一個元素。

AI 模式 全部 圖片 影片 新聞 更多 ▾



- 對於有限群 S_5 ，拉普拉斯矩陣有離散的特徵值。
- 對於無限自由群 F_2 ，其拉普拉斯算子的譜是一個連續區間 $[4 - 2\sqrt{3}, 4 + 2\sqrt{3}]$ （這是著名的 Kesten 不等式結果）。

4. 映射回群運算

在 F_2 的矩陣中， $L_{ij} = -1$ 僅發生在：

- $w_j = w_i \cdot a$
- $w_j = w_i \cdot a^{-1}$
- $w_j = w_i \cdot b$
- $w_j = w_i \cdot b^{-1}$

總結：

由於沒有交換性， F_2 的 Schreier 矩陣是極度**稀疏且對稱**的，且完全沒有迴圈。這使得它的 **LDL^T 分解** 呈現出一種遞迴的純淨結構，常用於構造無限群上的隨機遊走模型。

您是否想嘗試將這個 5×5 的 F_2 局部矩陣進行 **LDL^T 分解**，看看它生成的 **SOS 項** 與有交換律的群有何不同？



Yes

我們來對 F_2 的局部拉普拉斯矩陣 L_{local} 進行 **LDL^T 分解**。這個過程會揭示「無交換性」如何轉化為代數上的平方和。

AI 模式 全部 圖片 影片 新聞 更多 ▾



$$\begin{pmatrix} -1 & 0 & 0 & 0 & 4 \end{pmatrix}$$

2. LDL^T 分解步驟

步驟 1：確定 D_{11} 與 L 的第一行

- $D_{11} = 4$
- L 的第一行元素（除對角線外）為 $L_{i1} = \frac{A_{i1}}{D_{11}} = \frac{-1}{4} = -0.25$

步驟 2：更新剩餘的對角線 D_{ii}

由於 F_2 沒有迴圈（非對角線除了第一列外全是 0），更新非常簡單：

- $D_{22} = 4 - (-0.25)^2 \cdot 4 = 4 - 0.25 = 3.75$
- $D_{33} = 4 - (0)^2 \cdot \dots - (-0.25)^2 \cdot 4$ （這部分不變） $= 3.75$
- 以此類推， $D_{22} = D_{33} = D_{44} = D_{55} = 3.75$

分解結果：

$$D = \text{diag}(4, 3.75, 3.75, 3.75, 3.75)$$

$$L = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ -0.25 & 1 & 0 & 0 & 0 \\ -0.25 & 0 & 1 & 0 & 0 \\ -0.25 & 0 & 0 & 1 & 0 \\ -0.25 & 0 & 0 & 0 & 1 \end{pmatrix}$$

3. 生成的平方和 (SOS)

設定變數 $x_e, x_a, x_{a^{-1}}, x_b, x_{b^{-1}}$ 對應群元素，二次型展開為：

AI 模式 全部 圖片 影片 新聞 更多 ▾



入 小 題 目 目 元 圖

2. 與 S_5 的對比：

如果是在 S_5 中，因為有交換關係 $s_1 s_3 = s_3 s_1$ ，矩陣中會出現額外的非零元素（例如在 x_a 和 x_b 的對應位置）。這會導致 D_{ii} 的計算變得複雜，且 SOS 會出現跨分支的交叉項，如 $(x_{s_1} - x_{s_3})^2$ 。

3. Rayleigh 與譜半徑：

注意到 D_{ii} 的值從 4 降到了 3.75。在無限延伸的 F_2 中，這個數值會收斂到一個特定常數。**Rayleigh 不等式**告訴我們，只要 D_{ii} 保持大於 0，這個無限群的拉普拉斯算子就是正定的，這也是證明 F_2 具有非消解性（non-amenability）的一種代數方式。

總結：

F_2 的 SOS 像是一朵向外擴散的星型花朵，沒有迴圈。而 S_5 的 SOS 則像是一張緊密交織的網。

您想看看如果加入 S_5 的交換關係式（例如 $s_1 s_2 s_1 = s_2 s_1 s_2$ ），這個 LDL^T 分解會發生什麼具體的「扭曲」嗎？



💬 Rayleigh 不等式的對象：我們通常用 Rayleigh 不等式來研究 ...

I use this to compare the var distance from uniform distribution.
How they are related?



這是一個非常深刻的直覺。你所關注的變異數距離（**Total Variation Distance, TV distance**）與譜隙（**Spectral Gap, λ_1** ）之間的關係，正是隨機遊走（Random Walk）理論的核心。

AI 模式 全部 圖片 影片 新聞 更多 ▾



- λ_1 (譜隙) 是取小的非零特徵值。它決定「距離 π 中「非穩定成分」衰減的速度。

2. 變異數距離 (TV Distance) 的衰減不等式

假設 P_t 是經過 t 步隨機遊走後的機率分佈， π 是均勻分佈。根據譜定理，兩者的 TV 距離滿足：

$$\|P_t - \pi\|_{TV} \leq \frac{1}{2} \sqrt{|G|} \left(1 - \frac{\lambda_1}{k}\right)^t$$

- $|G|$ 是群的大小 (對於 S_5 是 120)。
- k 是生成元的數量 (對於 A_4 是 4)。
- 關鍵點： λ_1 越大， $(1 - \lambda_1/k)$ 就越小，距離均勻分佈的收斂速度就呈指數級加速。

3. 如何連結回 Rayleigh 不等式與 SOS ?

這就是你提到的「余裕」(Margin) 概念：

- Rayleigh 不等式的角色：

Rayleigh 商 $R(x) = \frac{x^T L x}{x^T x}$ 。當 x 與均勻分佈 (全 1 向量) 正交時， $R(x)$ 的最小值就是 λ_1 。如果你能透過 **SOS (LDL^T)** 證明 $L \succeq \gamma (I - \Pi)$ (其中 Π 是投影到均勻分佈的算子)，那麼 γ 就是譜隙的一個下界。

- SOS 的保證：

當你用 LDL^T 分解成功寫出 SOS 時，你實際上是在構造一個**能量泛函**。如果分解出來的對角項 D_{ii} 很大，代表這個群的連通性極佳 (像 S_5 這種擴展圖性質)，那麼隨機遊走在每一步都會損失大量的「偏離能量」，迫使分佈極快地拍平 (Flatten) 到均勻分佈。

4. S_5 vs. F_2 的對比

- S_5 (Coxeter A_4)：因為是有限群且具有高度對稱性，它有一個顯著的譜隙 λ_1

AI 模式 全部 圖片 影片 新聞 更多 ▾



下界推導出精確的步數。



So each step of random walk equals to one matrix multiplication?

沒錯，你的理解完全正確。在隨機遊走的數學模型中，矩陣乘法就是狀態轉移的代數表現。

具體對應關係如下：

1. 矩陣乘法 = 隨機遊走的一步

假設 P 是轉移機率矩陣（Transition Matrix），它與你提到的 **Schreier** 矩陣 M 關係極其密切：

$$P = \frac{1}{k} M$$

（這裡 k 是生成元的數量，對於 A_4 的 S_5 來說 $k = 4$ 。矩陣中的每個 1 變成了 $1/4$ ，代表你有 $1/4$ 的機率選擇某個相鄰對換）。

- 初始狀態：用向量 v_0 表示（例如，如果你從單位元出發， $v_0 = [1, 0, 0, \dots, 0]$ ）。
- 第 1 步後的分佈： $v_1 = v_0 P$
- 第 t 步後的分佈： $v_t = v_0 P^t$

為什麼這跟 Schreier 矩陣有關？

AI 模式 全部 圖片 影片 新聞 更多 ▾



3. 幾何直覺

每次矩陣乘法，其實就是將目前的機率分佈沿著 Schreier 圖的邊「擴散」出去：

1. **Schreier 矩陣** 告訴你機率可以流向哪些鄰居。
2. **LDL^T 分解** 則像是在這個擴散過程中找到了一組「正交的漏斗」，告訴你機率是如何在不同維度上衰減的。
3. **Rayleigh 不等式** 給出了這個擴散最慢（最困難）的方向。

總結

- 一步隨機遊走 = 乘以一次轉移矩陣 P 。
- t 步隨機遊走 = 矩陣的 t 次冪 P^t 。
- **變異數距離 (TV Distance)** = 向量 $v_0 P^t$ 與全域平均向量 π 之間的 L1 距離。

如果你能透過 SOS 證明 λ_1 （譜隙）很大，那就意味著矩陣乘法只需要少數幾次，初始向量 v_0 的突出部分就會被迅速「磨平」，達到均勻分佈。

你現在是在處理 S_5 具體的 120×120 矩陣冪次運算，還是想從理論上直接估計其收斂步數 (Mixing Time)？



So if we multiply two Schreier matrices, what does this multiplication means?

AI 模式 全部 圖片 影片 新聞 更多 ▾



- M^1 ：告訴你哪些排列是「一步之遙」的鄰居。
- M^2 ：告訴你哪些排列是「兩步之遙」的鄰居，以及到達那裡的路徑數。

2. 在 S_5 (Coxeter A_4) 中的具體意義

假設從單位元 e 出發：

- 對角線元素 $(M^2)_{ii}$ ：
這代表從 e 出發走兩步回到 e 的路徑數。在 S_5 中，因為有 4 個生成元 s_1, s_2, s_3, s_4 ，且每個生成元都是自己的逆元 ($s_i^2 = e$)，所以你走出去再走回來有 4 種方式 ($s_1s_1, s_2s_2, s_3s_3, s_4s_4$)。因此，對角線會全是 4。
- 非對角線元素 $(M^2)_{ij}$ ：
這反映了群的交換關係式。例如，如果 $s_1s_2 = s_2s_1$ (在 A_4 中這不成立，但 $s_1s_3 = s_3s_1$ 成立)，那麼從 e 到 s_1s_3 就會有兩條路徑 ($e \rightarrow s_1 \rightarrow s_1s_3$ 和 $e \rightarrow s_3 \rightarrow s_3s_1$)，矩陣對應位置的值就會是 2。

3. 與「變異數距離」的深度聯繫

當你計算 M^t 時，你實際上是在追蹤隨機遊走的機率波如何擴散：

- M^t 的每一列之和：在 S_5 中始終是 4^t 。
- 歸一化：如果我們看 $P^t = (\frac{1}{4}M)^t$ ，矩陣中的數值就是機率。
- 趨向均勻：隨著 $t \rightarrow \infty$ ， P^t 的每一個元素都會趨近於 $\frac{1}{120}$ 。

4. 與 LDL^T 分解的關聯

為什麼我們要分解 $L = 4I - M$ 而不是直接乘 M ？

因為矩陣乘法 M^t 雖然直觀，但在代數上很難看出「何時收斂」。而 LDL^T 分解處

AI 模式 全部 圖片 影片 新聞 更多 ▾



時，就代表你的洗牌（Shuffle）已經達到了均勻分佈。

你是否觀察到在 S_5 中，經過某個特定步數（例如 $t = 20$ ）後，矩陣元素開始劇烈地趨向平均值？那通常就是 **Mixing Time** 發生的地方。



Give me concrete matrices of these multiplication and result as an equation

為了讓你看到最具體的結果，我們使用 S_3 （對稱群，6 個元素）作為例子，因為它的矩陣大小（ 6×6 ）足以展示 S_n 的特性，且結果清晰可見。在 A_2 展示中，生成元為 $s_1 = (1, 2)$ 和 $s_2 = (2, 3)$ 。


1. Schreier 矩陣 M (一步)

這是 S_3 的鄰接矩陣。每一行代表一個排列，若透過 s_1 或 s_2 可互換，則值為 1。

$$M = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 1 & 0 \end{pmatrix}$$

2. 矩陣乘法 M^2 (兩步)

我們計算 $M \times M$ 。這個結果告訴我們從起點走 2 步到達終點的路徑數。



AI 模式 全部 圖片 影片 新聞 更多 ▾



- 关系如 1，例如 (1, 4) 且 1 与 4 相邻，则 $s_1 s_2$ 与 $s_2 s_1$ 不相邻，因此在中 $s_1 s_2 \neq s_2 s_1$ 。

3. 與拉普拉斯矩陣 L 及 SOS 的方程式聯繫

在隨機遊走理論中，我們關心的是如何從 M 轉向均勻分佈。我們定義歸一化的轉移矩陣為 $P = \frac{1}{2} M$ （因為 S_3 只有 2 個生成元）。

這與 **Rayleigh 不等式** 和 **LDL^T** 的關聯可以總結為以下方程式：

A. 能量擴散方程式 (Energy Dissipation)

對於任何分佈向量 v ，走一步後的「能量」差為：

$$v^T L v = v^T (2I - M) v = \sum_{(i,j) \in E} (v_i - v_j)^2$$

這就是 **SOS** 的由來：拉普拉斯矩陣保證了它可以寫成節點間差值的平方和。

B. 譜Gap 與收斂 (Convergence)

若 λ_1 是 L 的最小非零特徵值（透過 Rayleigh 商 $\min \frac{v^T L v}{v^T v}$ 得到），則 t 步後的結果滿足：

$$\|P^t v - \pi\|^2 \leq \left(1 - \frac{\lambda_1}{2}\right)^{2t} \|v - \pi\|^2$$

4. 具體結論

當你把 M 乘到 M^t 時：

1. 矩陣元素變平：在 M^2 中我們還有很多 0，但在 M^6 或更高次方後，所有元素

AI 模式 全部 圖片 影片 新聞 更多 ▾



💬 所有元素都會變成正數。

Why this means uniform distribution?

這是一個非常關鍵的直覺點。「所有元素變成正數」並不直接等於均勻分佈，但它是通往均勻分佈的**必要第一步**，在數學上這代表群的**連通性 (Connectivity)** 和**非週期性 (Aperiodicity)**。

以下是為什麼矩陣元素「變正」與「均勻分佈」有關的邏輯鏈條：

1. 從「不可達」到「可達」

- 矩陣中的 **0**：代表從狀態 A 走 t 步絕對不可能到達狀態 B 。
- 變為正數：當 M^t 的所有元素都大於 0，意味著無論你從 S_5 的哪一個排列開始，經過 t 步後，都有機率到達群中的**任何一個位置**。
- 這在馬可夫鏈中被稱為**不可約性 (Irreducibility)**。

2. 消除「濃度」，趨向「平坦」

隨機遊走的本質是機率的「擴散」。

- 一開始，機率集中在單位元 e （矩陣中只有一個位置是 1，其他是 0）。
- 每乘以一次 M （或歸一化的 P ），機率就會被「平均」分給鄰居。
- 當 t 足夠大，且所有路徑都連通時（所有元素皆為正），機率波會發生疊加與抵

AI 模式 全部 圖片 影片 新聞 更多 ▾



是每個位置機率都相等的狀態。

- 方程式： $\pi M = k\pi$ （其中 $\pi = [1, 1, \dots, 1]$ ）。
- 當 $t \rightarrow \infty$ 時， $P^t = (\frac{1}{k} M)^t$ 會收斂到一個矩陣，其每一項都是 $1/|G|$ （在 S_5 中是 $1/120$ ）。

4. 與 LDL^T / SOS 的聯繫

這就是你研究的重點：

- LDL^T 分解 衡量的是「偏離均勻分佈的程度」。
- 當 M^t 的元素全部變正時，代表譜隙 λ_1 開始發揮作用，強勢地壓制非均勻的成分。
- Rayleigh 不等式 保證了這個「變正」的過程是單向且不可逆的：能量一旦擴散出去，就不會再聚集回某個單一點。

總結

「元素全正」意味著機率已經滲透（Percolated）到了整個群空間。一旦滲透完成，由於群結構的對稱性，物理上的「擴散」力會迫使這些正數互相趨近，直到它們完全相等——這就是均勻分佈。

你是在觀察 M^t 中最大值與最小值的差距 嗎？那個差距（ L_∞ norm）正是衡量隨機遊走「洗牌」是否完全的最嚴格指標。需要我示範如何用譜隙 λ_1 來推算這個差距縮小的速度嗎？



So uniform distribution means such a matrix that all elements are

AI 模式 全部 圖片 影片 新聞 更多 ▾



$$\Pi = \begin{pmatrix} \frac{1}{120} & \frac{1}{120} & \cdots & \frac{1}{120} \\ \frac{1}{120} & \frac{1}{120} & \cdots & \frac{1}{120} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{120} & \frac{1}{120} & \cdots & \frac{1}{120} \end{pmatrix}$$

特徵：所有的元素都是正數，且數值完全相同。

2. 這代表什麼意義？

- **與起點無關**：無論你從哪一個排列（哪一行）出發，經過足夠多步後，到達任何一個排列（哪一行）的機率都是相等的（1/120）。
- **洗牌完全 (Perfect Shuffle)**：這代表你的 S_5 序列已經被徹底打亂，沒有任何規律可循。

3. 如何用你提到的工具來衡量「接近程度」？

既然均勻分佈矩陣 Π 的所有元素都相同，那麼：

- **變異數距離 (TV Distance)**：就是你的實際矩陣 P^t 與這個「全相等矩陣 Π 」之間的數值差異。
- **LDL^T 分解與 SOS**：當你分解拉普拉斯矩陣 L 時，你實際上是在證明：除了那個對應於「全相等狀態」的特徵值 0 之外，其他的特徵值 ($\lambda_1, \lambda_2 \dots$) 都夠大。
- **Rayleigh 不等式**：它給出的 λ_1 越小，你的矩陣 P^t 的元素要變得「全部相同」所需的時間就越長。

總結

矩陣元素**全部變正**代表「機率已經傳播到全場」；矩陣元素**全部相等**則代表「機率已經徹底平衡」，這正是均勻分佈在矩陣語言中的定義。

您是否想看看在 S_5 的 A_4 展示下，大約需要幾次矩陣相乘（步數）才能讓元素之間的差異縮小到可以忽略不計？

AI 模式 全部 圖片 影片 新聞 更多 ▾



這是一個非常關鍵的觀察！原因在於**「路徑計數」與「機率分布」**這兩個概念之間的轉換。

1. 為什麼數字會變大？（路徑計數）

當你直接將 **Schreier 矩陣** M 相乘時，你是在計算**「路徑的數量」**。

- M^1 ：走 1 步，有 4 種可能（生成元數量 $k = 4$ ）。
- M^2 ：走 2 步，有 $4 \times 4 = 16$ 種路徑。
- M^t ：走 t 步，總共有 4^t 種路徑。
這就是為什麼 M^t 的元素會越來越大。在 S_5 中，每一列的元素總和會等於 4^t 。

2. 為什麼會變成 1/120？（歸一化機率）

要觀察均勻分布，我們不能直接看路徑總數，必須看**「每一條路徑發生的機率」**。我們需要將矩陣歸一化（Normalize）**：

我們定義 **轉移矩陣** $P = \frac{1}{4} M$ （每個元素除以生成元總數）。

現在，每一列的總和固定為 **1**（代表機率總和為 100%）。

當你計算 P^t 時：

- P^1 ：元素是 $1/4 = 0.25$ 。
- $P^2 = P \times P$ ：元素會是路徑數除以總機率空間（例如 $1/16, 2/16$ 等）。
- P^t ：隨著 t 越來越大，這 4^t 條路徑會均勻地散佈到 S_5 的 120 個元素中。

3. 數學極限

對於 S_5 （120 個元素）：

AI 模式 全部 圖片 影片 新聞 更多 ▾



4. 這跟你的 LDL^T 有什麼關係？

當你在做 LDL^T 分解 時，你處理的是 $L = I - P$ 。

- 這個矩陣的特徵值介於 0 到 2 之間。
- L 衡量的是**「不均勻度」的減少速度**。
- **Rayleigh 不等式** 告訴你，那個 0.00833 的極限值，每多乘一次矩陣，誤差會縮小多少比例。

總結：

數字變大是因為你在**「數路徑」；變成 1/120 是因為你在「分機率」**。

您是否想嘗試計算一下，對於 S_5 來說，大約要乘到 M 的幾次方，路徑數在各個排列之間的分布才會趨近於 1: 1: 1...？

